

MBA  
USP  
ESALQ

*Séries Temporais*

Prof. Dr. Ricardo Limongi


# Agenda

- Revisão da aula anterior
- ARIMA
- SARIMA
- Prophet

*Hernandes Matias Junior 124.799.116-40*

# Interações

- Indicação de Livros em Português
- Conteúdo da disciplina
  - Determinístico e estocástico
  - Conceitos e principais técnicas
- Aula Final
- Dica sobre carreira
- Oportunidade de estudo na Plataforma Kaggle




# Vimos na Aula Anterior...


- Séries Temporais
  - Conjunto de observações feitas em sequência ao longo do tempo
- Componentes:
  - Sazonalidade
    - Padrões de comportamento que se repetem em específicas épocas do ano
  - Tendência
    - Padrão de crescimento/decrescimento da variável em um certo período de tempo
  - Resíduo/Ruído
    - Capta os efeitos que não foram incorporados pela série de tempo, ou seja, o resíduo

# Vimos na Aula Anterior...

Sazonalidade




Tendência



# Vimos na Aula Anterior...

- Estacionariedade
  - Série não muda ao longo do tempo e facilita a previsão
  - Condições:
    1. Média constante e o desvio padrão sem efeito de sazonalidade
    2. Avaliação por meio do Teste de Dicky-Fuller
    3. Avaliação do p valor do teste




# Vimos na Aula Anterior...

- Autocorrelação
  - Autocorrelação (ACF)
    - Relação existente entre as observações ao longo do tempo
  - Autocorrelação parcial (PACF)
    - Fornece a correlação parcial de uma série de tempo estacionária com seus próprios valores defasados regredindo os valores da série de tempo nas defasagens mais curtas. Contrasta com a função de autocorrelação, que não controla para outras defasagens.

# Vimos na Aula Anterior...

- Autocorrelação





# Vimos na Aula Anterior...

- Lags:
  - **Tempo de atraso** na série para calcular as correlações.
  - As defasagens são criadas após o deslocamento da série e, em seguida, compare a série defasada com a série original sem defasagem

Date	Value	Value <sub>t-1</sub>	Value <sub>t-2</sub>
1/1/2017	200	NA	NA
1/2/2017	220	200	NA
1/3/2017	215	220	200
1/4/2017	230	215	220
1/5/2017	235	230	215
1/6/2017	225	235	230
1/7/2017	220	225	235
1/8/2017	225	220	225
1/9/2017	240	225	220
1/10/2017	245	240	225

# Ajustamento Exponencial

## Suavização Exponencial Simples

sem tendência e sazonalidade, parâmetro  $\alpha$

## Holt's Suavização Exponencial

com tendência , parâmetro  $\alpha$  e  $\beta$

## Holt-Winter Suavização Exponencial

com tendência e sazonalidade, parâmetro  $\alpha$  ,  $\beta$  e  $\gamma$

# ARIMA

- **AR → Modelo Autoregressivo**

- A variável de interesse é uma regressão linear de valores passados da própria variável, o que implica que o futuro depende do passado. É composto por “p” observações defasadas da variável de interesse mais um ruído, que captura o que não é explicado pela regressão.

- **I → Integrado**

- Refere-se a diferentes métodos, computando diferenças entre observações consecutivas, para obter um processo estacionário a partir de um processo não estacionário. É definido pelo parâmetro “d”, que descreve o número de vezes que as observações são diferenciadas.

- **MA → Modelo de Média Móvel**

- É um modelo semelhante a uma regressão que recorre a erros de previsão anteriores para prever a variável de interesse, além de um ruído. A média móvel tem ordem “q” e define o tamanho da janela da média móvel.

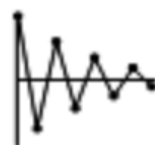

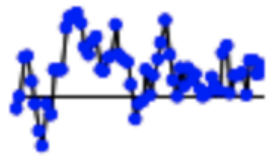
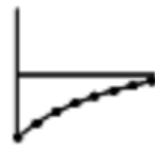







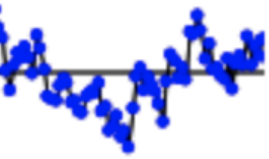

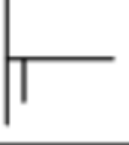

# ARIMA

ARIMA: Modelo Autoregressivo, integrado e de média móvel

## Parâmetros

- $P$ , termo autoregressivo
- $D$ , número de diferenciações
- $Q$ , termo da média móvel

# ARIMA

Nº	ACF	PACF	Tendência	ARIMA(p,d,q)	Observação
1				(2, 0, 0)	
2				(1, 1, 1)	Box-Cox
3				(0, 1, 2)	
4				(0, 0, 1)	
5				(1, 0, 0)	

Fonte: Midomenech (2020)

# ARIMA

AR: modelo autoregressivo AR (p) ou ARIMA (p,0,0):  $y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$

MA: apenas média móvel MA (q) ou **ARIMA (0,q,0)**:  $y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$

Junção de AR e MA: ARMA (p,q) ou ARIMA (p,0, q):  $y'_t = c + \phi_1 y'_{t-1} + \dots + \phi_p y'_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t$

Com a diferenciação: ARIMA (p,d,q)

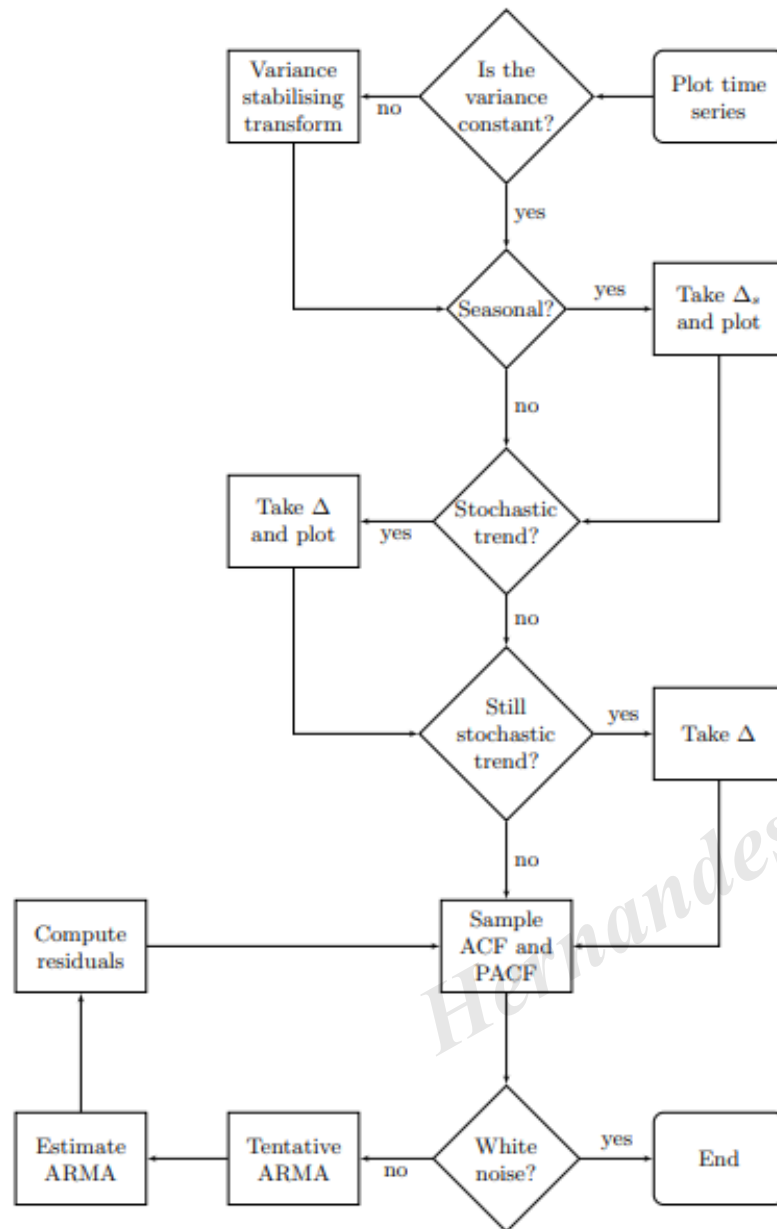
Com a sazonalidade: ARIMA (p,d,q,) (P,D,Q)

# SARIMA

SARIMA: Modelo Autoregressivo Sazonal, integrado e de média móvel

## Parâmetros

- $P$ , termo autoregressivo
- $D$ , número de diferenciações
- $Q$ , termo da média móvel
- $M$ , período sazonal (período anual 12, quadrimestre 4, ....)



Fonte: Box e Jenkins (1974)

### Procedimento para avaliação dos parâmetros

Eventuais transformações necessárias:

- Diferenças entre 1a ou 2a ordem para remover tendências
- Diferença para remover efeitos sazonais
- Transformação logarítmica em caso de não estacionariedade



# Prophet

Baseado em modelo aditivo

$$y(t) = g(t) + s(t) + h(t) + \epsilon t$$

$g(t)$  = representa tendência

$s(t)$  = representa sazonalidade

$h(t)$  = representa os eventos

# Autocorrelação

**Correlação:** quão relacionado é um valor com outro valor (isso não significa que um valor influenciou o outro)

**Autocorrelação (ACF):** comparação do valor presente com valores do passado da mesma série.

A diferença entre a autocorrelação e a autocorrelação parcial (PACF)

ACF: correlação direta e indireta

PACF apenas a correlação direta.

Exemplificando: no ACF vemos a correlação direta do mês de janeiro em março e também a correlação indireta que o mês de janeiro teve em fevereiro que também teve em março.

Prof. Dr. Ricardo Limongi



[linkedin.com/in/ricardolimongi/](https://www.linkedin.com/in/ricardolimongi/)